

Artificial Neural Network





본 챕터의 일부는 김성훈 박사님의 "모두를 위한 머신러닝/딥러닝 강의 (https://hunkim.github.io/ml/)" 자료를 참고하여 편집하였습니다.

XOR by PyTorch



```
import numby as np
import torch.nn as nn
from sklearn.metrics import accuracy_score

# 데이터 위기 함수
def load_dataset(file, device):
    data = np.loadtxt(file)
    print("DATA=",data)

# input_features = torch.tensor(input_features, dtype=torch.float).to(device)
    labels = torch.tensor(labels, dtype=torch.float).to(device)
    return (input_features, labels)

# 모델 평가 결과 계산물 위해 덴서를 리스트로 변환하는 함수
def tensor2list(input_tensor):
    return input_tensor.cpu().detach().numpy().tolist()
```

```
| Train.txt - Windows 메모장
파월(F) 편집(E) 서식(O) 보기(V) 도용할(H)
0 0 0
0 1 1
1 0 1
1 1 0
```



```
DATA= [[0. 0. 0.]
[0. 1. 1.]
[1. 0. 1.]
[1. 1. 0.]]
INPUT_FEATURES= [[0. 0.]
[0. 1.]
[1. 0.]
[1. 1.]]
LABELS= [[0.]
[1.]
[0.]]
```

Edited by Harksoo Kim

XOR by PyTorch

```
# GPU 사용 가능 여부 확인
if torch.cuda.is_available():
 device = 'cuda'
else:
 device = 'cpu'
input_features, labels = load_dataset("/gdrive/My Drive/colab/ann/xor/train.txt",device)
# NN 모델 만들기
model = nn.Sequential(
         nn.Linear(2, 2, bias=True), nn.Sigmoid(),
         nn.Linear(2, 1, bias=True), nn.Sigmoid()).to(device)
# 이진분류 크로스멘트로피 비용 함수
loss_func = torch.nn.BCELoss().to(device)
# 옵티마이저 함수 (역전파 알고리즘을 수행할 함수)
optimizer = torch.optim.SGD(model.parameters(), Ir=1)
                                                                     = -\frac{1}{m} \sum y log(H(x)) + (1-y)log(1-H(x))
# 학습 모드 셋팅
model.train()
                                                                     W := W - \alpha \frac{\partial}{\partial W} cost(W)
```



XOR by PyTorch

학습 실행 및 코스트 출력 예측(0과 1로 변환) 및 정밀도 계산 #모델 학습 # 평가 모드 셋팅 (학습 시에 적용했던 드랍 아웃 여부 등을 비적용) for epoch in range(1001): # 기울기 계산한 것들 초기화 # 역전파를 적용하지 않도록 context manager 설정 optimizer.zero_grad() with torch.no_grad(): hypothesis = model(input features) # H(X) 계산: forward 연산 logits = (hypothesis > 0.5).float() hypothesis = model(input_features) predicts = tensor2list(logits) golds = tensor2list(labels) # 비용 계산 print("PRED=".predicts) cost = loss_func(hypothesis, labels) print("GOLD=",golds) # 역전파 수행 print("Accuracy : {0:f}".format(accuracy_score(golds, predicts))) cost.backward() 0.6988072395324703 optimizer.step() 200 0.6930413246154785 300 0.692793071269989 # 100 에폭마다 비용 출력 400 0.6919294595718384 if epoch % 100 == 0: 500 0.6865977048873901 600 0 6376820802688599 print(epoch, cost.item()) 700 0.5430010557174683 800 0 3161814212799072 900 0.0973285436630249 1000 0.051614370197057724 PRED= [[0.0], [1.0], [1.0], [0.0]] GOLD= [[0.0], [1.0], [1.0], [0.0]] Accuracy : 1.000000

Edited by Harksoo Kim

Shallow ANN

```
Hidden layer를 없애고 Single-layer Perceptron으로 변경
```

```
# NN 모델 만들기
model = nn.Sequential(
nn.Linea(2, 1) bias=True), nn.Sigmoid()).to(device)
```

Non-linear Separable Problem

학습 속도는 빠르지만 10,000 epoch를 수행해도 문제를 풀지 못함

```
0 0.7842277884483337
1000 0.6931471824645995
2000 0.6931471824645995
3000 0.6931471824645996
4000 0.6931471824645996
5000 0.6931471824645996
5000 0.6931471824645996
5000 0.6931471824645996
5000 0.6931471824645996
5000 0.6931471824645996
5000 0.6931471824645996
5000 0.6931471824645996
5000 0.6931471824645996
5000 0.6931471824645996
5000 0.6931471824645996
5000 0.6931471824645996
```



Wide ANN

Hidden layer를 2*2에서 2*10으로 변경 # NN 모델 만들기 Widening은 선의 개수를 늘리는 효과! 더 빨리 수렴함 (학습 속도는 느려짐) 0 0.6988072395324707 0 0.7083522081375122 100 0.693162202835083 100 0.6920320987701416 200 0.6930413246154785 200 0.6887232065200806 300 0.692793071269989 300 0.6461161971092224 400 0.6919294595718384 400 0.3004415035247803 500 0.09012892842292786 500 0.6865977048873901 600 0.04456526041030884 600 0.6376820802688599 700 0.028334952890872955 700 0.5430010557174683 800 0.020417045801877975 800 0.3161814212799072 900 0.0973285436630249 900 0.01582087203860283 1000 0.051614370197057724 1000 0.01284930482506752 PRED= [[0.0], [1.0], [1.0], [0.0]] GOLD= [[0.0], [1.0], [1.0], [0.0]] PRED= [[0.0], [1.0], [1.0], [0.0]] GOLD= [[0.0], [1.0], [1.0], [0.0]] Accuracy : 1,000000 Accuracy : 1.000000

Deep ANN

Hidden layer 층을 1개에서 2개로 변경 # NN 모델 만들기 ?

오래 걸리지만 학습됨


0 0.6935569821813965 100 0.6930767893791199 200 0.6930528283119202 300 0.6930522833119202 300 0.6930521297454364 400 0.692977547645688 500 0.6929132342339562 600 0.6928118467330933 700 0.692857026309967 800 0.692969918115234 900 0.6915065319704346 1000 0.6915065319704346 900 0.69106629959595 PRED- [[1.0], [0.0], [1.0], [0.0]] 60UD- [[0.0], [1.0], [1.0], [0.0]] 구부리는 효과! 0 0.7725627422332764 300 0.693066048962738

Deeping은 선을


600 0. 6929765939712524 900 0. 69272780418356 1200 0. 691035151 4816284 1500 0. 5800561 4454841614 1800 0. 095045225918293 2100 0. 014179595240568638 2400 0. 0076338378712534904 2700 0. 0052098375745117664 3000 0. 003449393518269062 PFED= [[0.0], [1.0], [1.0], [0.0]] GOLD= [[0.0], [1.0], [1.0], [0.0]] Accuracy : 1.000000



Deeper ANN




Sigmoid to ReLU



Edited by Harksoo Kim

Vanishing Gradient



Sigmoid to ReLU


Sigmoid (10,000 epoch) ReLU (3,000 epoch)


0 0.6933478713035583 1000 0.5931472420592444 2000 0.5931472420592444 3000 0.5931471824645996 4000 0.5931471824645996 5000 0.5931471824645996 6000 0.5931471824645996 6000 0.5931471824645996 9000 0.5931471824645996 9000 0.5931471824645996 9000 0.5931471824645996 9000 0.5931471824645996 9000 0.5931471824645996 9000 0.5931471824645996 9000 0.5931471824645996 9000 0.5931471824645996 0 0.6946406960487366 300 0.6931304931640625 600 0.6931031942367554 900 0.69302482643738 1200 0.6929616196250916 1500 0.6929618293952942 1800 0.6677674055093467 2100 0.0012112652393836975 2700 0.00014955494982637465 3000 9.424101881450042e-05 PBEP= [(0.0), [1.0), [1.0], [0.0]] 90UP= [(0.0), [1.0], [1.0], [0.0]] Vanishing

gradient 문제가 사라짐



Activation Functions







Regularization

- Regularization (정규화, 일반화)
 - Cost function 값이 작아지는 방향으로 학습하는 과정에서 특정 가중치가 너무 커져서 일반화 성능이 떨어지는 것을 방지하기 위한 방법

$$D(S,L) = -\frac{1}{N} \sum_{i} L_{i} log(S_{i}) + \lambda \sum_{i} |W| \circ \begin{cases} a = [0.1, 0.5, 0.2] \rightarrow ||a|| = 8 \\ b = [0.3, 0.5, 0.0] \rightarrow ||b|| = 8 \end{cases}$$


- L2 Regularization

- Early Stopping
 - Dev set에서 성능이 더 이상 증가하지 않을 때 지정 횟수보다 학습을 일찍 끝마치는 것
- Dropout

Edited by Harksoo Kim

Fitting


• 적합






Dropout

- 드롭아웃
 - 학습 과정 중에 지정된 비율로 임의의 연결을 끊음으로써 일반 화 성능을 개선하는 방법





(a) Standard Neural Net

(b) After applying dropout.

그림 출처: https://medium.com/@gopalkalpande/biological-inspiration-of-convolutional-neural-network-cnn-9419668898ac



Dropout by PyTorch

```
# NN 모델 만들기
model = nn.Sequential(
          nn.Linear(2, 10, bias=True), nn.ReLU(), nn.Dropout(0.1)
          nn.Linear(10, 10, bias=True), nn.ReLU()
                                                   nn.Dropout(0.1
          nn.Linear(10, 10, bias=True), nn.ReLU()
                                                   nn.Dropout(0.1
                                                                             DATA= [[0. 0. 0.]
          nn.Linear(10, 10, bias=True), nn.ReLU()
                                                   nn.Dropout(0.1
          nn.Linear(10, 10, bias=True), nn.ReLU()
                                                  nn.Dropout(0.1
          nn.Linear(10, 10, bias=True), nn.ReLU() nn.Dropout(0.1)
                                                                              INPUT_FEATURES= [[0. 0.]
          nn.Linear(10, 10, bias=True), nn.ReLU() nn.Dropout(0.1
          nn.Linear(10, 1, bias=True), nn.Sigmoid()).to(device)
                                                                             [1. 1.]]
LABELS= [[0.]
# 이진분류 크로스엔트로피 비용 함수
loss_func = torch.nn.BCELoss().to(device)
# 옵티마이저 함수 (역전파 알고리즘을 수행할 함수)
optimizer = torch.optim.SGD(model.parameters(), Ir=0.2)
                                                                              0 0.7056415677070618
300 0.6939449310302734
 # 학습 모드 셋팅
                                                                              600 0.6798115968704224
                                                                              900 0.6760240197181702
 model.train()
                                                                              1200 0.7288740873336792
                                                                              1500 0.5377387404441833
                                                                              1800 0.4900955557823181
# 평가 모드 셋팅 (학습 시에 적용했던 드랍 아웃 여부 등을 비적용
                                                                              2100 0.00430224509909749
                                                                              2400 0.2083825021982193
                                                                              2700 0.6571221351623535
                                                                              3000 0.0671871230006218
# 역전파를 적용하지 않도록 context manager 설정
                                                                             PRED= [[0.0], [1.0], [0.0]]
GOLD= [[0.0], [1.0], [1.0], [0.0]]
Accuracy: 1.000000
with torch.no_grad():
 hypothesis = model(input_features)
```



질의응답



Homepage: http://nlp.konkuk.ac.kr E-mail: nlpdrkim@konkuk.ac.kr



Residual Connection

- 추가 연결
 - 가중치층을 우회하여 상위 층으로 직접 연결하는 것
 - 추상화 정도(낮은 수준 추상화와 높은 수준 추상화)를 적절히 섞 어주는 효과 → 앙상블 효과를 통해 성능 개선

